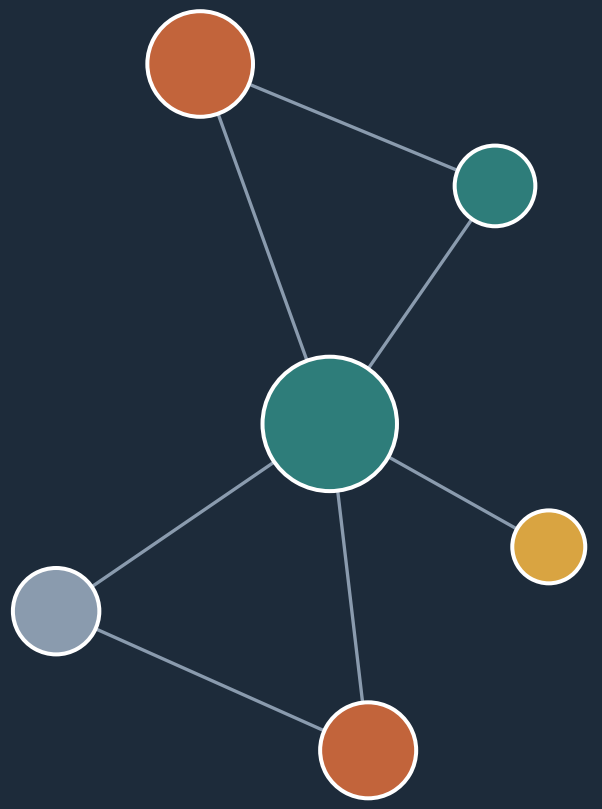
Une plateforme de gestion des connaissances fondée sur un Knowledge Graph enrichi par un LLM

Conception, développement et évaluation d'une architecture hybride RAG / GraphRAG pour un contexte bancaire



Projet de fin d'études — Master Data Engineering · [Prénom NOM — à compléter] · Année universitaire 2025–2026

Une connaissance écrite, mais difficile à mobiliser

Dispersion

Les dépendances de CoreNova sont réparties entre un compte rendu, une note d'architecture et une cartographie

Versions

La procédure KYC existe en version 1.0 (revue à 24 mois) et 2.0 (12 mois)

Contradictions

Le guide de l'outil Sentinel KYC indique encore 24 mois

Diffusion restreinte

Le plan de continuité n'est diffusé qu'à trois directions

Doublons

Copies exactes et copies de travail coexistent avec l'original

Expertise

Savoir qui maîtrise la lutte anti-blanchiment est aussi utile que le texte

Problématique et questions de recherche

Comment permettre à un collaborateur d'interroger la documentation interne d'une banque en langage naturel, en obtenant des réponses exactes, sourcées et conformes à ses droits, y compris lorsque la réponse relie plusieurs documents, entités et versions ?

QR1 Le graphe améliore-t-il la recherche pour les questions relationnelles et multi-sauts ?

QR2 Le graphe dégrade-t-il les questions factuelles simples ?

QR3 Le contrôle de suffisance permet-il de s'abstenir à bon escient ?

QR4 Des preuves typées trouvent-elles mieux les experts qu'un comptage de mentions ?

QR5 Contenu + graphe recommandent-ils mieux que le contenu seul ?

Démarche : un banc d'essai bancaire synthétique

35

documents d'une banque fictive

66

questions annotées, 10 catégories

5

architectures comparées

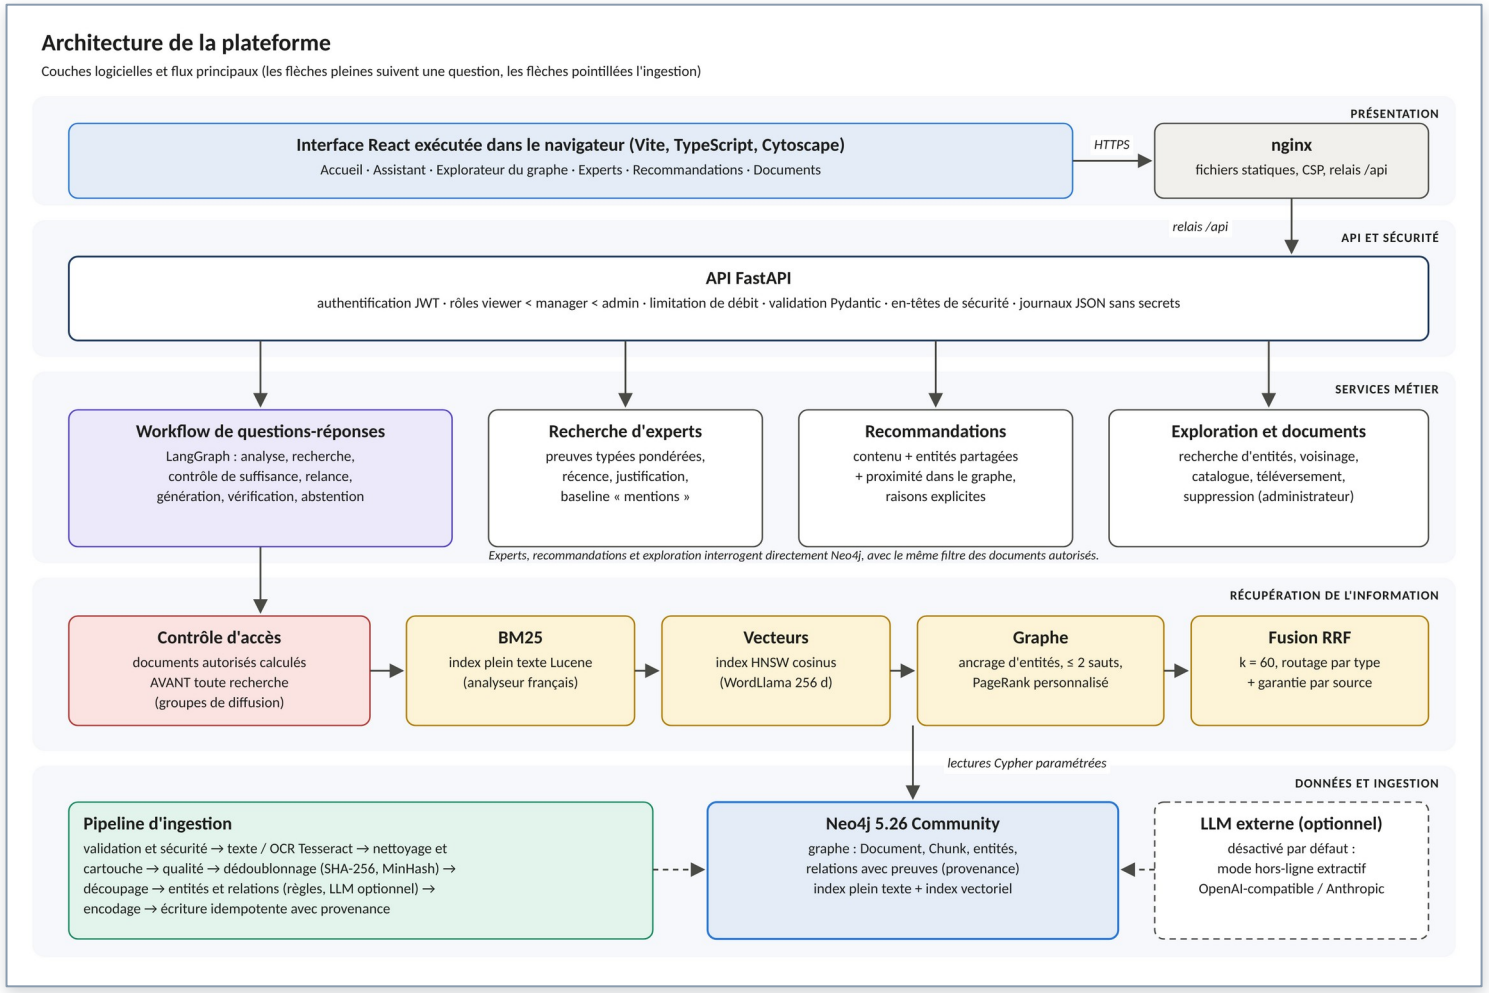
0

donnée réelle d'entreprise

Des pièges intégrés volontairement

- Versions successives d'une même procédure
- Valeurs contradictoires : 12 ou 24 mois, 33 ou 40 %
- Doublon exact et copie de travail
- Note de service scannée, lue par OCR
- Cinq documents à diffusion restreinte
- Mémo contenant une injection de prompt

Architecture : six couches, un LLM optionnel



LLM optionnel

Sans clé, tout fonctionne hors-ligne : règles d'extraction et générateur extractif

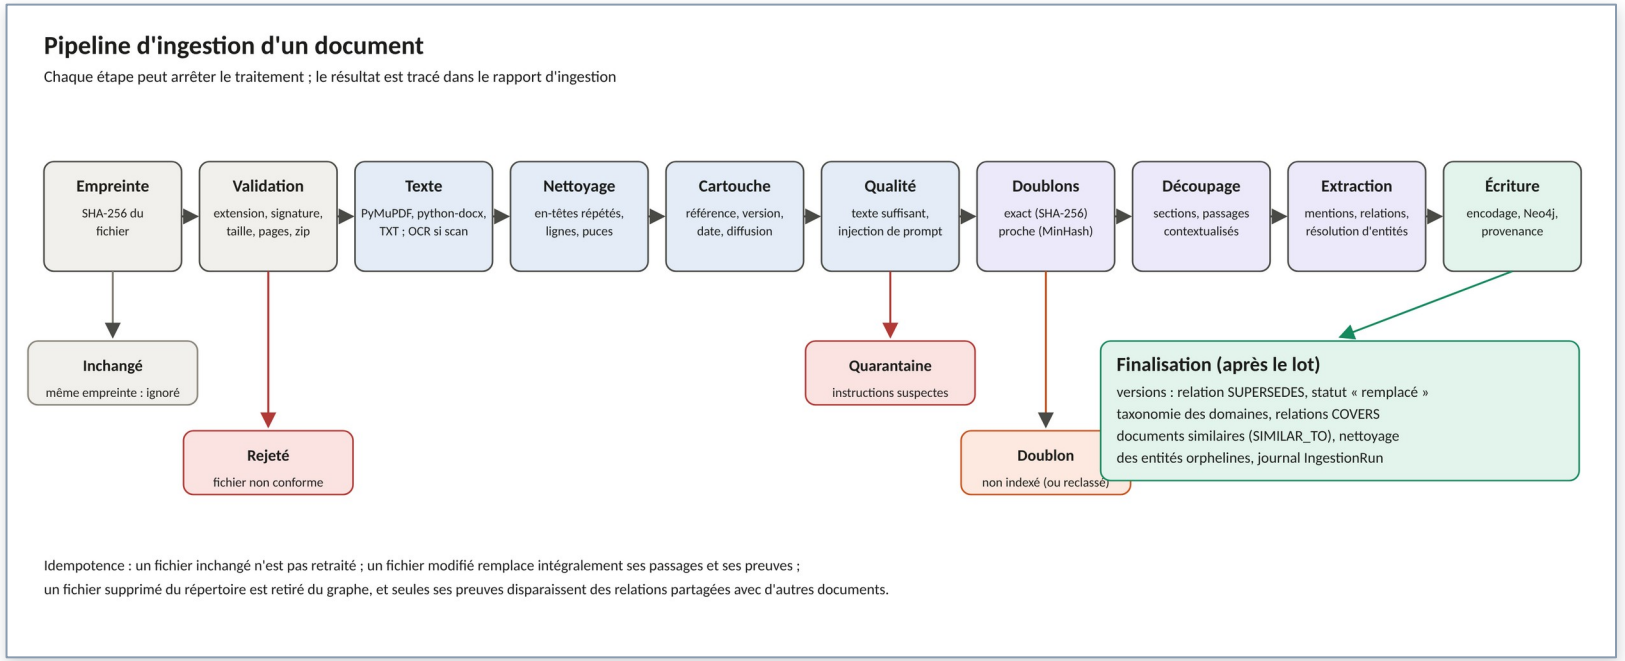
Une seule base

Neo4j porte le graphe, l'index vectoriel et l'index plein texte

Droits dès le départ

Documents autorisés calculés avant toute recherche

Du document au graphe, avec la provenance de chaque fait



AML Watch → dépend de → CoreNova

un seul fait, trois documents, trois citations exactes, extracteur et confiance pour chaque preuve : retirer un document retire les faits qu'il était seul à justifier

31	documents actifs
1 + 2	version remplacée, doublons
1	quarantaine (injection)
18,45 s	ingestion complète
0,38 s	relance sans changement

Trois sources de preuves, fusionnées et routées

BM25

mots exacts : sigles, références, valeurs

Vecteurs

sens proche, paraphrases (WordLlama)

Graphe

entités de la question, voisinage à 2 sauts, PageRank personnalisé

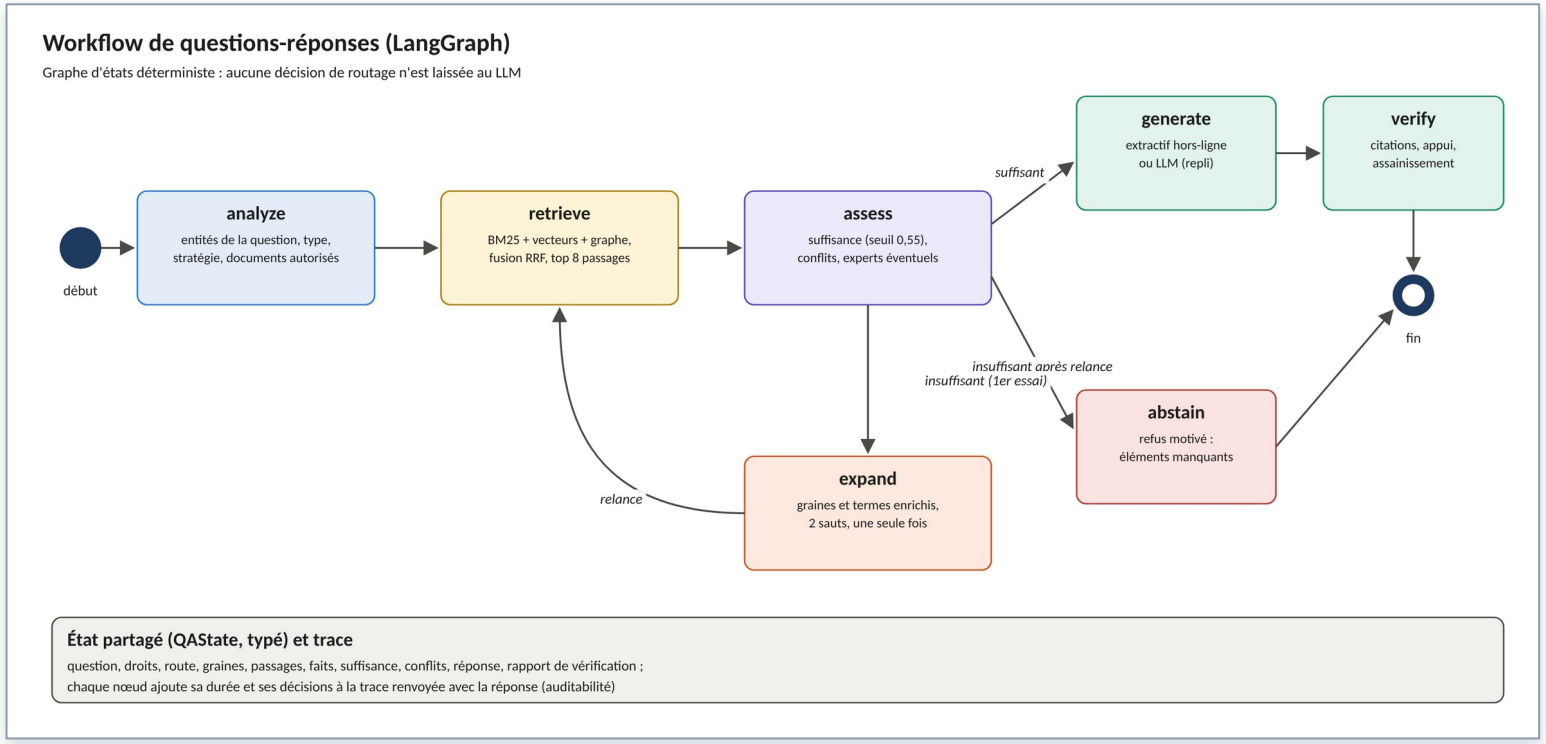
Fusion RRF
rangs seuls, k = 60

Routage selon le type de question

Type	Poids du graphe	Sauts
factuelle	0,5	1
relationnelle	1,0	2
multi-sauts	1,5	2
expertise	1,0	1
ambiguë	1,0	2

Le graphe seul est excellent sur le relationnel mais dégrade le factuel : le routage dose son poids.

Un workflow qui vérifie avant et après la génération



LangGraph comme automate à états : le LLM, s'il est configuré, n'intervient que dans la génération et ne choisit jamais l'étape suivante.

Suffisance

couverture des termes pondérée par l'IDF (seuil 0,55), entités, valeur chiffrée

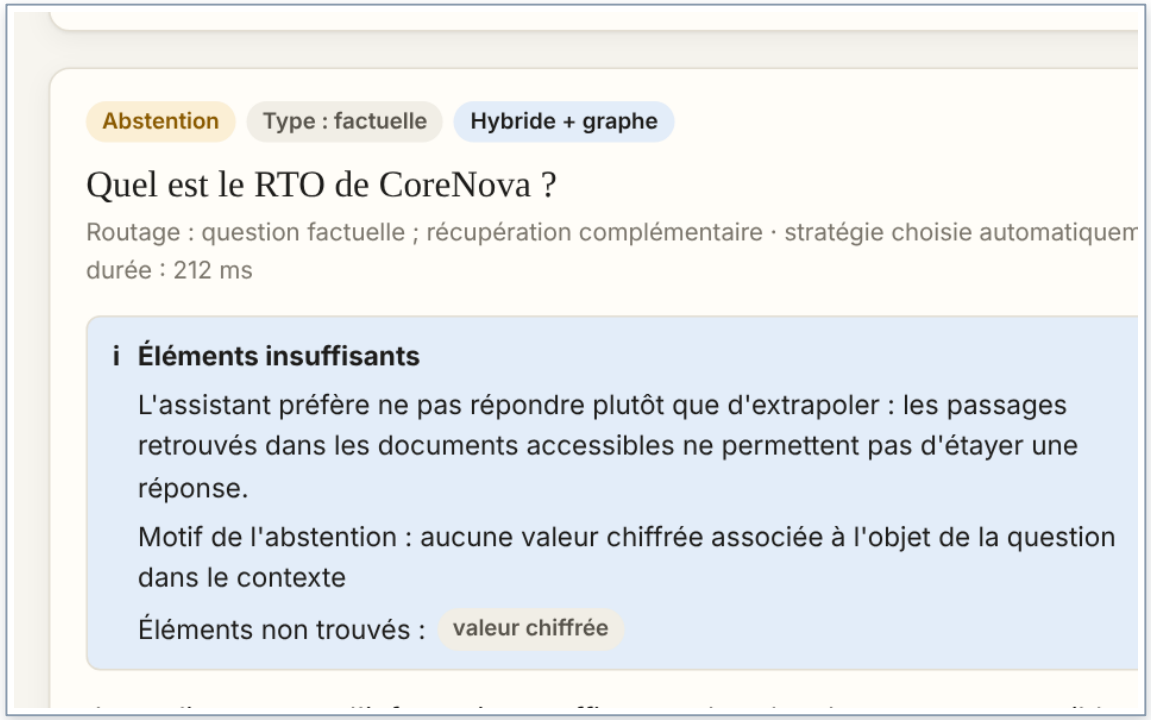
Une relance au plus

graines et termes enrichis, puis génération ou abstention

Vérification

citations réelles, phrases appuyées, liens et HTML retirés

Sécurité : filtrer avant de chercher



Compte « collaborateur » : abstention, sans révéler l'existence du plan de continuité



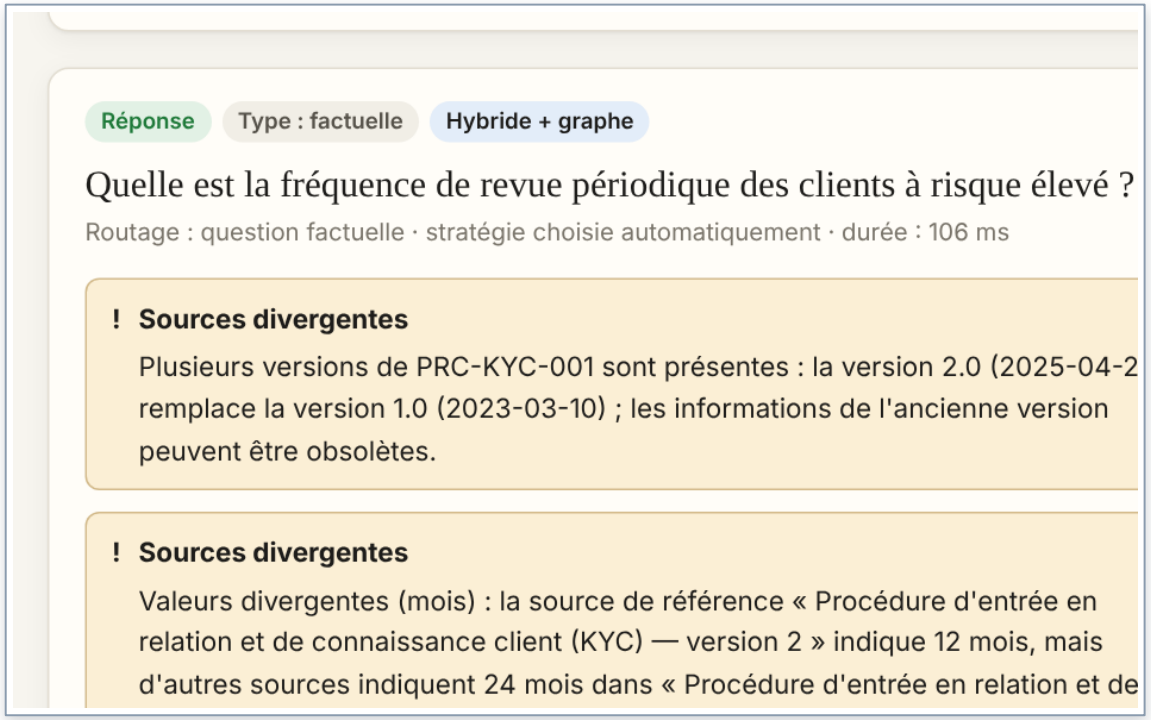
Compte « ingenieur.dsi » : « RTO : 4 heures », avec sa source

0 fuite sur 990 réponses rejouées avec 3 comptes restreints · mémo piégé en quarantaine · diffusion absente = refus

Démonstration : relations citées et contradictions signalées

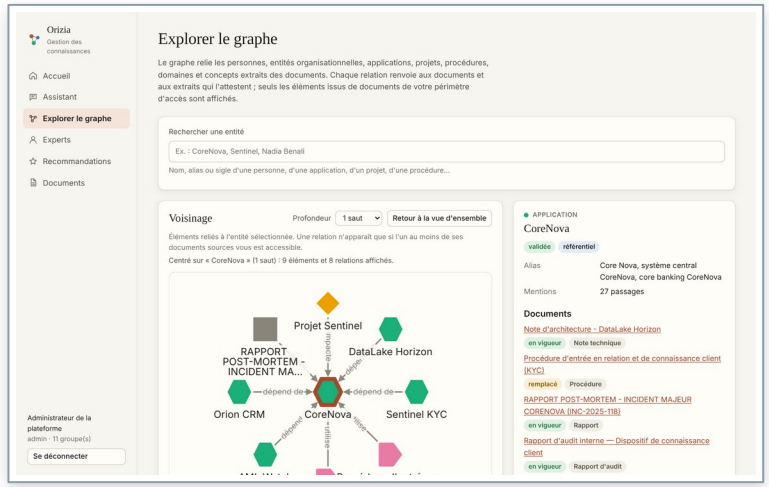


« **Quelles applications dépendent de CoreNova ? »** faits du graphe [F] et passages [C], tous cliquables



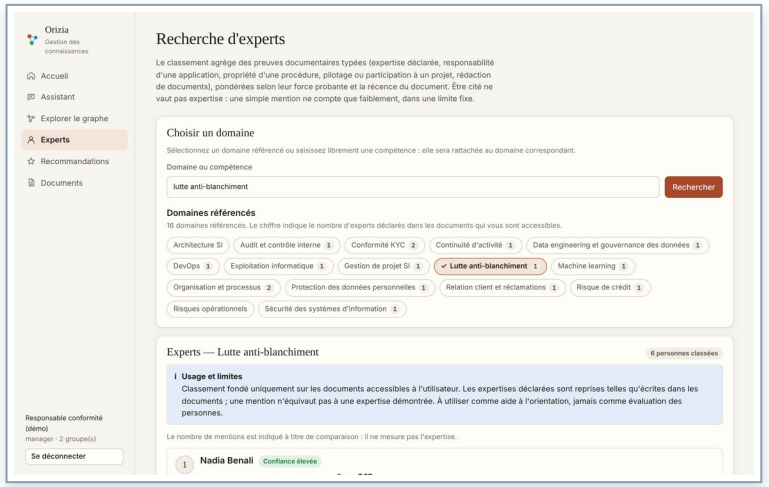
Revue des clients à risque élevé : 12 mois selon la procédure en vigueur ; l'outil et l'ancienne version disent 24 mois

Explorer le graphe, trouver les experts, recommander



Explorateur

voisinage de CoreNova, filtré par les droits



Experts

classement justifié par des preuves typées (rôle manager)



Recommandations

documents liés à la procédure KYC v2, avec leurs raisons

Interface React + Cytoscape.js, politique de sécurité du contenu stricte ; aucune page n'accède directement à la base.

Un protocole conçu contre le sur-ajustement

1

Partition des documents

règles mises au point sur D01–D20, testées sur D21–D35

2

Questions séparées

17 de développement, 49 jamais inspectées avant la campagne

3

Configuration gelée

puis campagne principale ; workflow identique pour les 5 architectures

4

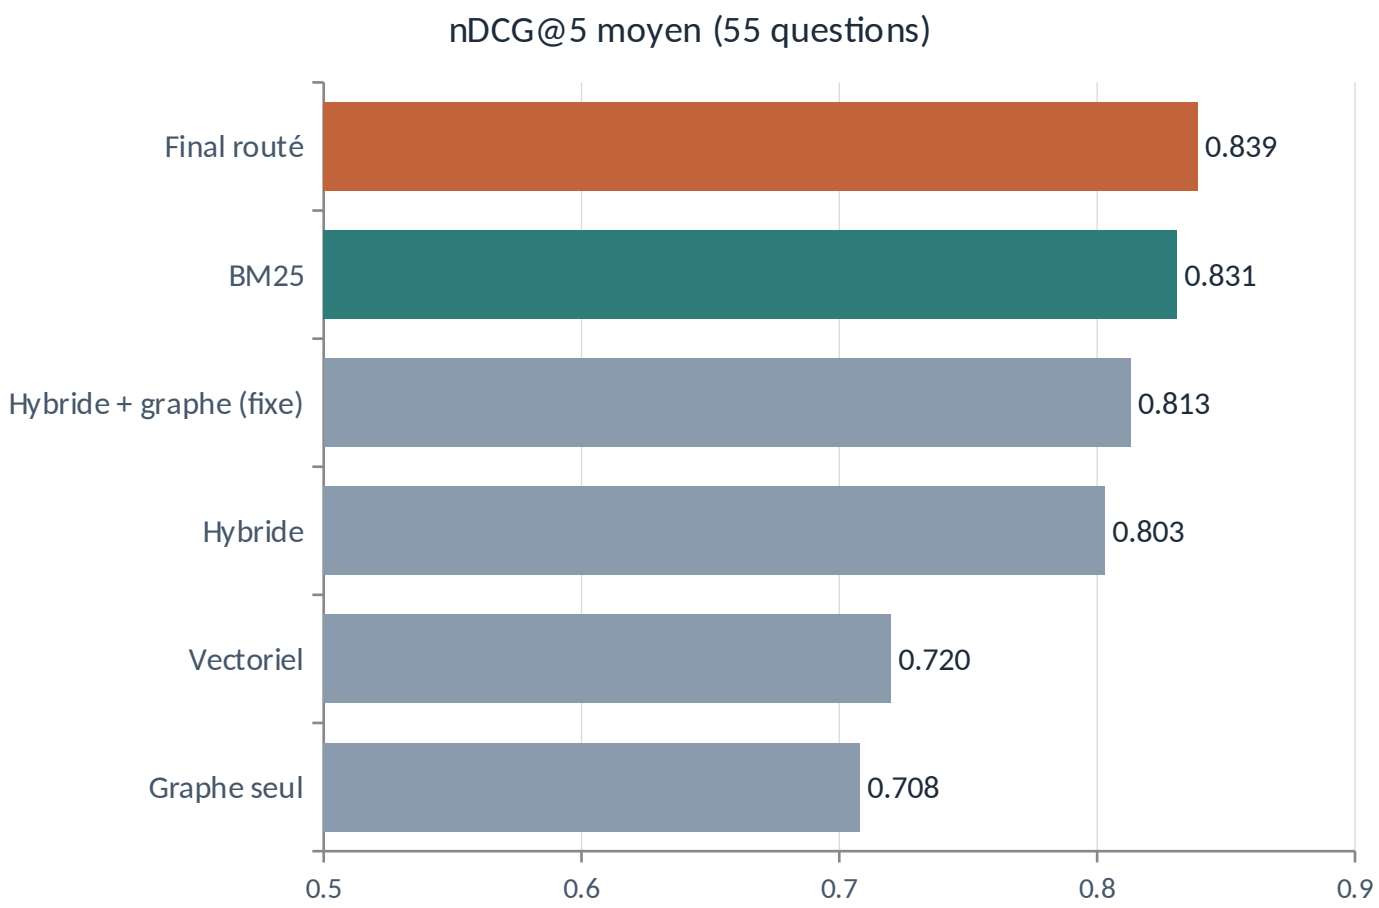
Journal post-gel

toute modification ultérieure tracée et mesurée à part

Métriques : Recall@5, MRR, nDCG@5 (pertinence graduée) pour la recherche ; exactitude par mots-clés, abstention, citations, fuites pour les réponses ; P@1, nDCG@3 pour les experts ; nDCG@5 pour les recommandations.

Statistiques : intervalles de confiance à 95 % par bootstrap (2 000 tirages) et test exact des signes sur données appariées.

Recherche : la fusion routée en tête, BM25 très proche



0,839

nDCG@5 du final [0,78 ; 0,90]

0,409 → 0,720

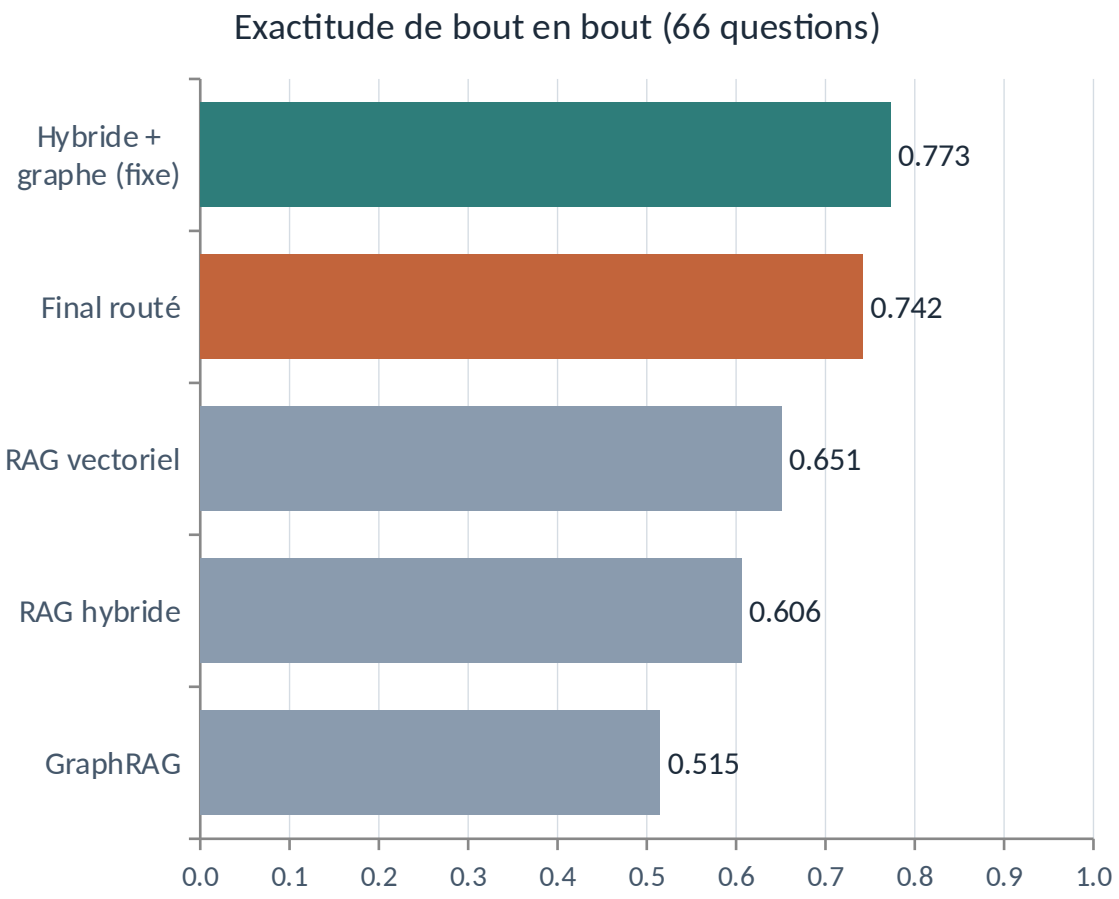
vectoriel : spaCy → WordLlama

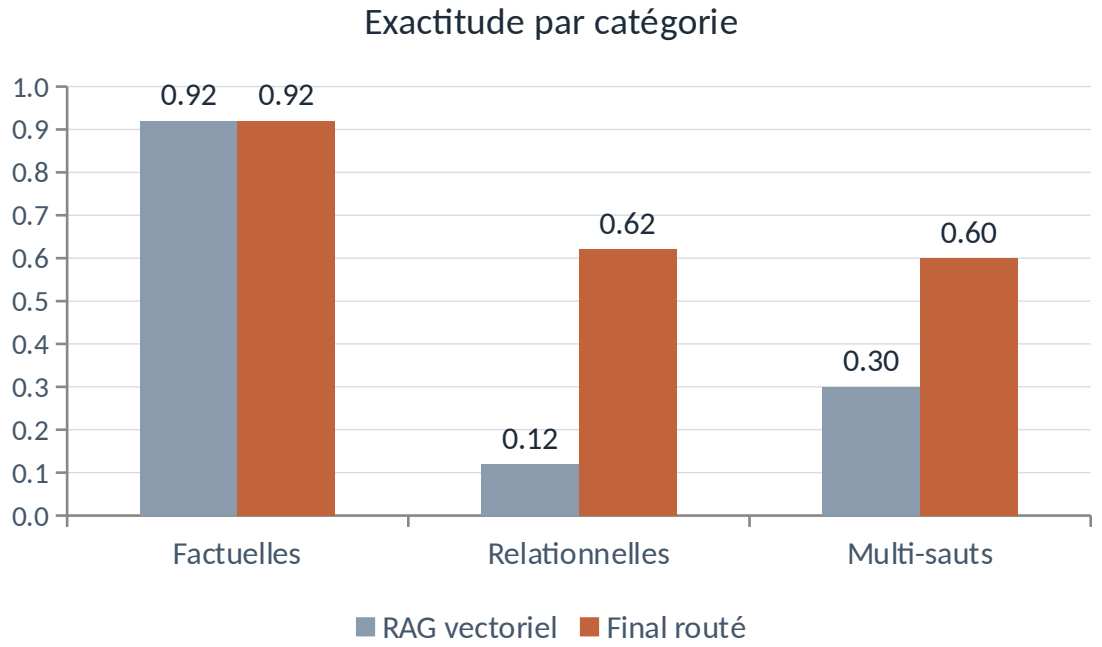
0,96 / 0,52

graphe seul : relationnel / factuel

Source : evaluation/results/RESULTATS.md — configuration gelée, encodeur WordLlama ; écart final – BM25 non significatif.

Réponses : le graphe change la donne sur les relations





0,882 sur les questions de développement, **0,694** sur les questions jamais inspectées : c'est le chiffre honnête.

Source : RESULTATS.md — générateur extractif hors-ligne ; final [0,64 ; 0,85] ; final − RAG hybride : p = 0,02 ; final − fixe : p = 0,5.

Fiabilité : aucune invention, mais trop d'abstentions

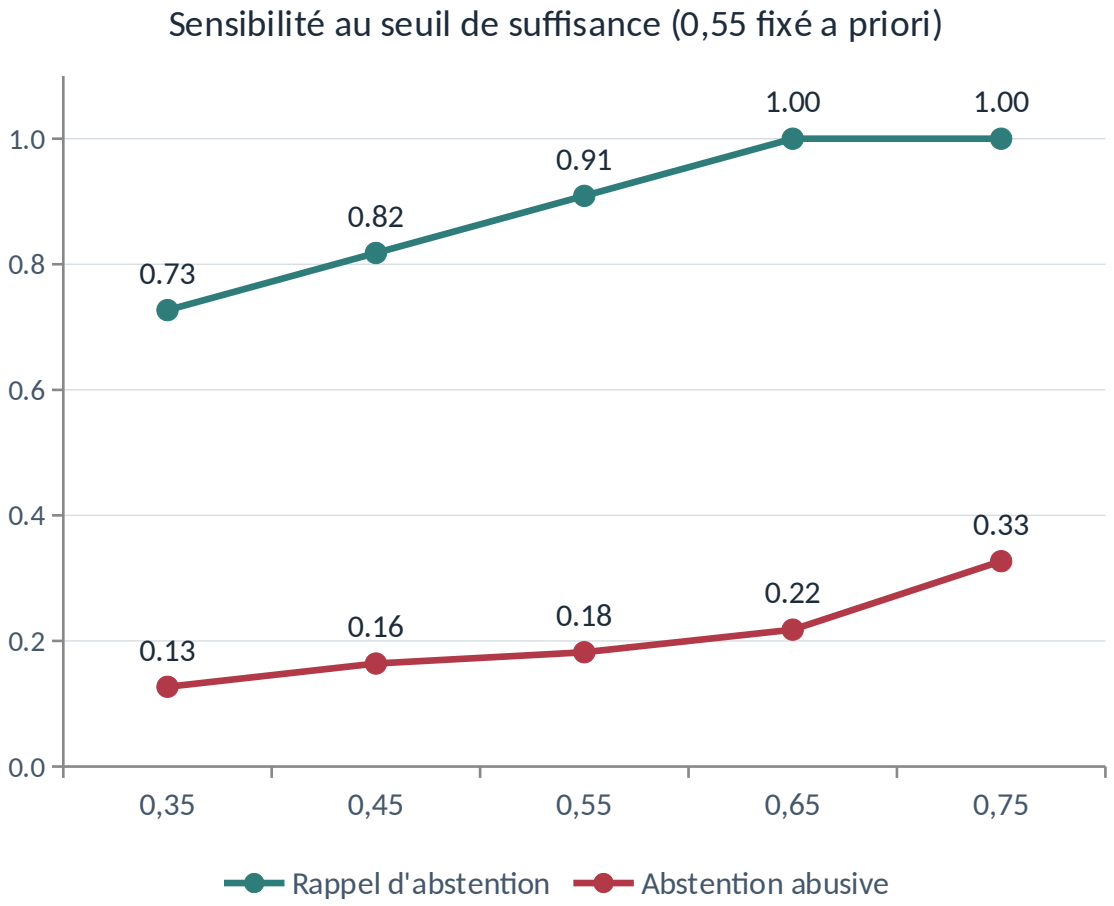
0
citation inventée

0
fuite d'accès

0
chaîne interdite

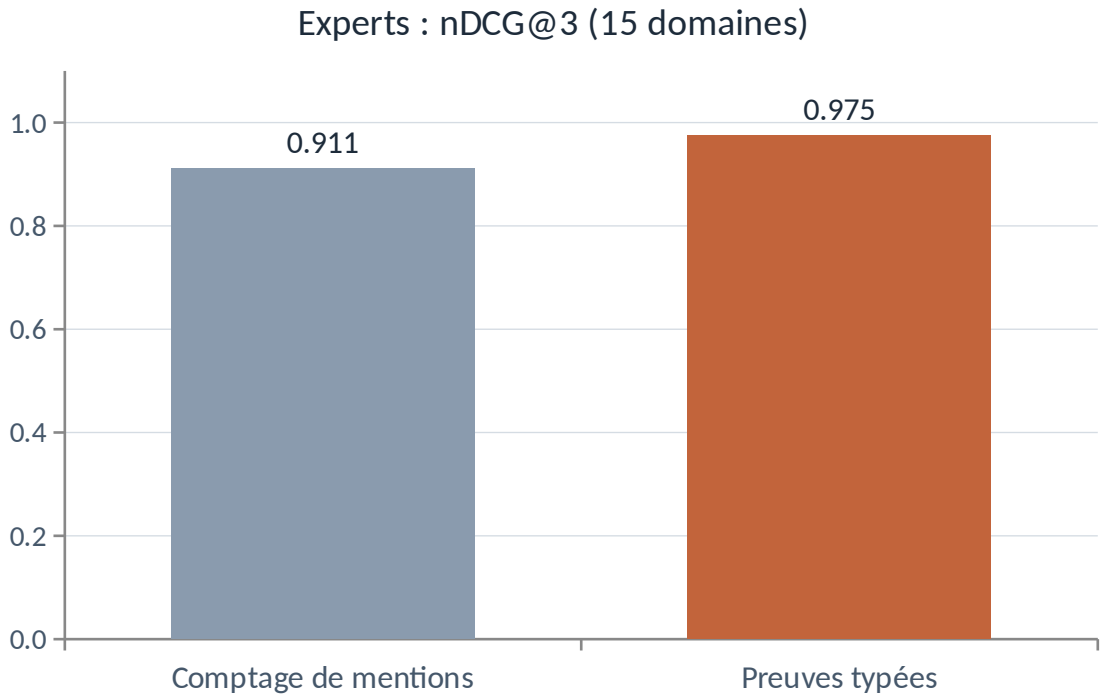
Abstention (final) : rappel 0,909 (10 sur 11), précision 0,5, **18 % d'abstentions abusives** : le contrôle lexical est sensible aux paraphrases.

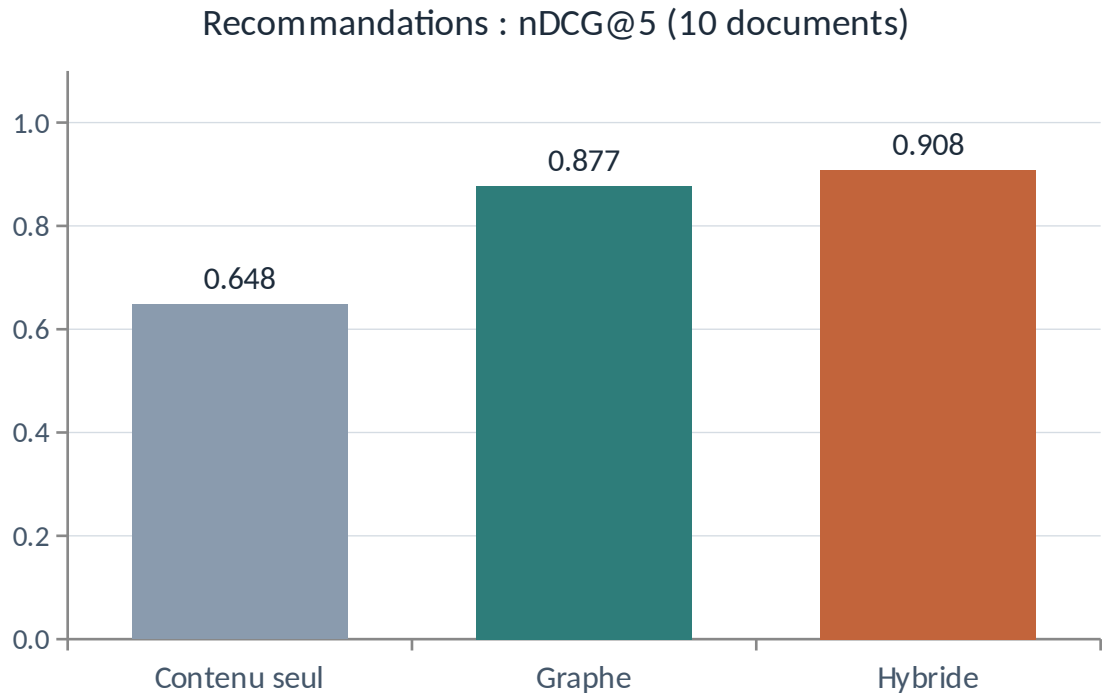
Le seuil règle un compromis métier : coût d'une réponse fausse contre coût d'une non-réponse.



Source : RESULTATS.md — sections 5 et 6 ; vérification des citations et filtrage des droits appliqués à toutes les architectures.

Experts et recommandations : le graphe apporte la justification





H4 non démontrée : écart de +0,064, p = 0,375 ; l'apport tient aux preuves affichées.

H5 validée : +0,261 sur le contenu seul, p = 0,004 ; aucun doublon recommandé.

Source : RESULTATS.md — sections 7 et 8 ; test exact des signes apparié.

Bilan des hypothèses de recherche

Hypothèse	Constat mesuré	Verdict
H1 — le graphe aide le relationnel et le multi-sauts	exactitude 0,12 → 0,62 et 0,30 → 0,60 ; en recherche, égal à l'hybride sur le relationnel	Partiellement
H2 — pas de dégradation du factuel	nDCG@5 0,99 et exactitude 0,92 grâce au routage	Validée
H3 — abstention à bon escient	rappel 0,909 mais 18 % d'abstentions abusives	Partiellement
H4 — experts par preuves typées	nDCG@3 0,975 contre 0,911, p = 0,375	Non démontrée
H5 — recommandations hybrides	nDCG@5 0,908 contre 0,648, p = 0,004	Validée

Menaces à la validité : corpus et questions conçus par la même personne, corpus synthétique et petit, 66 questions, mesures lexicales, encodeurs légers.

Déployer en banque : une trajectoire et une gouvernance



analyse de risques, sécurité, DPO

un domaine, questions réelles annotées par les métiers

SSO, supervision, sauvegardes automatisées

domaine par domaine, gouvernance en place

Gestionnaire des connaissances

valide entités candidates et quarantaine

Contrôle par échantillonnage

la conformité relit un échantillon de réponses

Experts : finalité limitée

orienter, jamais évaluer ; avis du DPO

Décision formelle sur le LLM

classification des données, contrat, réévaluation

Limites assumées et perspectives

Limites

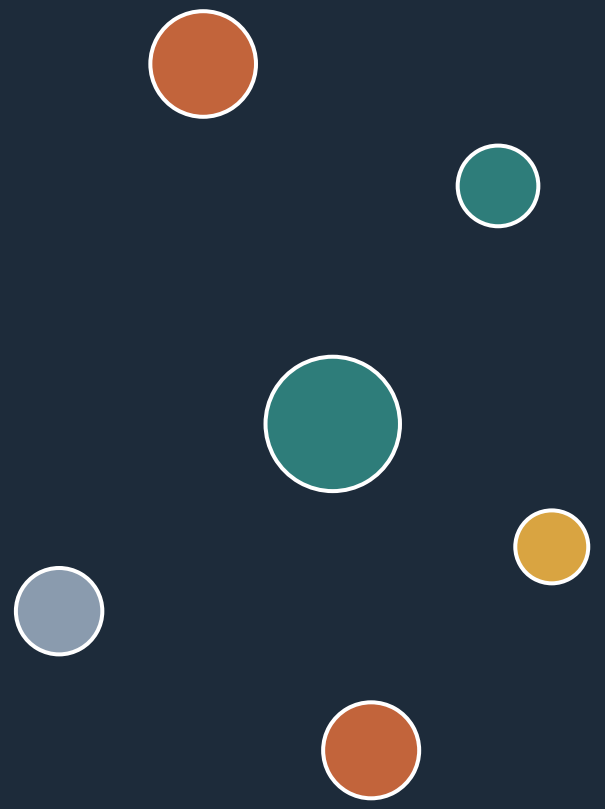
- Aucun LLM évalué : aucune clé disponible
- Corpus synthétique, conçu par l'auteure
- Encodeurs légers, hors-ligne
- Suffisance lexicale : 18 % d'abstentions abusives
- Rappel des règles 0,717 sur les documents de test
- Aucun déploiement distant ; pas prête pour la production

Perspectives

- Rejouer la campagne avec un LLM, plus une relecture humaine
- Pilote sur documents réels, questions des métiers
- Encodeur neuronal multilingue
- Contrôle de suffisance sémantique
- Écran de validation des entités candidates
- GraphRAG global : résumés de communautés

Ce qui fait la valeur d'un assistant documentaire en banque

- Une plateforme complète, du fichier brut à la réponse citée
- Une évaluation honnête : le graphe aide là où on l'attend
- Des droits, une provenance et une gouvernance pensés dès la conception



Merci de votre attention